SpecFlow

Разведочный анализ данных (EDA)

Автоматическое извлечение характеристик товаров из текстовых карточек
Кейс М.Видео — маркетплейс электроники

Источник	Строк	Сущность
sku_desc.parquet	1 177 200	текстовые карточки (title, description)
skus.pkl (YML)	546 069	офферы каталога + параметры-атрибуты
query_clicks.parquet	30 991 350	поисковые клики (трафик)

Отчёт сгенерирован автоматически: 16.10.2026. Все числа получены скриптами пакета `EDA/src` непосредственно из датасета.

1. Краткое резюме

- Датасет состоит из трёх независимых срезов: **1 177 200** текстовых карточек, **546 069** офферов каталога с разметкой атрибутов и **30 991 350** строк кликового трафика.
- Эталонные атрибуты есть только у офферов каталога: в среднем **38,4** параметра на товар, суммарно **20 975 702** присвоений по **10 708** уникальным именам (после слияния дублей `_search`).
- Связность источников низкая: карточки и каталог пересекаются лишь по **241 355** SKU, во всех трёх сразу — **102 945** SKU (18,9% от каталога).
- Бренд и модель отлично «заземляются» в тексте: у бренда значение найдено в заголовке в **98,2%** случаев, у модели — **95,9%**. Цвет же в тексте почти не встречается (**16,8%**) — его нельзя брать из текста без обращения к структурным полям.
- Текст карточек «грязный»: **49,3%** описаний содержат HTML-теги, **44,4%** — `<br>`; **41,1%** заголовков — дубликаты.
- Таксономия огромна и имеет длинный хвост: **10 708** имён атрибутов, из них **5 486** встречаются реже 100 раз. Офферов всего **546 069**, то есть на большинство атрибутов примеров крайне мало.
- Структурированные поля каталога **уже нормализованы** (единицы в отдельном `@unit`, значения — из ограниченных словарей), а вот входной текст — нет. Это подтверждает выбор гибридного пайплайна: правила/словари для ядра + ML/LLM для хвоста и свободного текста.

Ключевой вывод для задачи

- Строить канонический справочник атрибутов и значений нужно **из структурированных параметров каталога**, а текст карточки использовать как неструктурированный вход для извлечения.
- Категория товара в карточках sku_desc **отсутствует** — её придётся выводить из текста или тянуть из каталога по SKU.
- Значительная часть «атрибутов» в каталоге — служебные (продавец, гарантия, подборки, BI-поля) и маркетинговые. Их нужно отфильтровать, оставив реальные товарные характеристики.
- Низкое пересечение источников — риск: обучаться/валидироваться можно только на подмножестве (102 945 SKU с текстом и трафиком одновременно).

2. Источники данных и схема

2.1. Карточки товаров — sku_desc.parquet

Поле	Тип	Описание	Пропусков
sku_id	int64	идентификатор SKU	0
title	str	название карточки	0
description	str	полное описание (HTML)	0

Объём: **1 177 200** строк, все SKU уникальны. Категории в файле нет.

2.2. Каталог — skus.pkl (формат YML)

Поле оффера	Тип	Описание	Заполнено
@id	str	идентификатор оффера (≈ SKU)	100%
name	str	название товара	100%
vendor	str	бренд (эталон)	100,0%
model	str	модель (эталон, часто составная строка)	100,0%
categories.categoryId	str	идентификатор категории	100%
param[]	list[dict]	параметры: @name, @unit, #text	100%
@available	bool	в наличии	100%

Модель категорий: 6 963 узла, дерево глубины до 3 уровней (3 599 категорий реально используются).

2.3. Кликовый трафик — query_clicks.parquet

Поле	Тип	Описание
sku_id	uint64	SKU, который показали/кликнули
query_text	str	поисковый запрос
sku_brand_name	str	бренд из выдачи
sku_subject_id	uint64	id тематики (совпадает с категориями каталога)
sku_seo_id	uint64	id SEO-группы
sku_price	float	цена, ₽
sku_position	uint64	позиция товара в выдаче

Объём: **30 991 350** строк; **332 753** уникальных SKU, **4 103** тематик, 15 показанных топ-запросов использованы в анализе.

3. Покрытие и связывание источников

Три файла — это разные снимки каталога, а не строго согласованные таблицы. Пересечение по SKU показано ниже и является ограничением задачи.



Рис. 1. Пересечение множеств SKU между источниками.

Регион	SKU
Только карточки (нет в каталоге)	880 632
Только офферы каталога (нет текста)	165 998
Офферы ∩ карточки (текст + эталон)	241 355
Офферы ∩ клики	241 661
Карточки ∩ клики	158 158
Во всех трёх источниках	102 945

Из **1 177 200** карточек лишь **241 355** (20,5%) имеют эталонную разметку атрибутов в каталоге. Это и есть потенциальная обучающая/валидационная выборка. Ещё **165 998** офферов каталога вообще не имеют текста — на них нельзя обучить извлечение, но можно использовать как словарь значений.

3.1. Заземление эталонных атрибутов в тексте

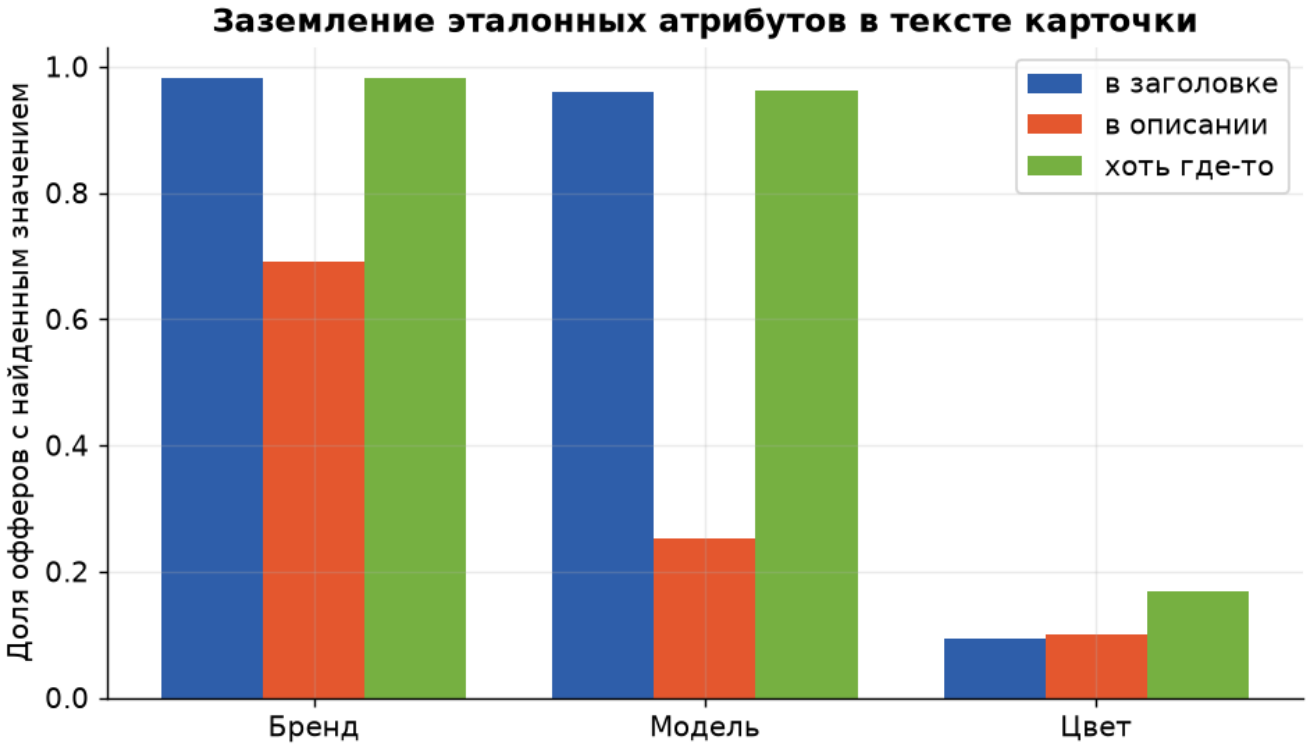


Рис. 2. Доля офферов, где эталонное значение найдено в тексте карточки.

Атрибут	Найдено в заголовке	Найдено в описании	Хоть где-то
Бренд (vendor)	98,2%	69,0%	98,2%
Модель (model)	95,9%	25,1%	96,2%
Цвет	9,3%	10,1%	16,8%

Бренд практически всегда присутствует в заголовке — это делает его самым надёжным атрибутом для правил. Модель тоже хорошо находится, но поле `model` в каталоге часто содержит не чистую модель, а длинную составную строку (цвет, память, парт-номер), поэтому его нужно нормализовать. Цвет в тексте почти не встречается: **его нельзя извлечь только из описания**, нужен словарь цветов и структурное поле. Также важно: бренд в каталоге в 90,4% случаев содержит латиницу, тогда как текст — преимущественно кириллица (транслитерации и разные написания).

Примеры, где модель НЕ найдена в заголовке:

sku_id	title	vendor	model
30027695	Картридж для лазерного принтера Xerox 106R01277 Black	Xerox	106R01277 черный
30028622	Планшет Apple iPad Pro 10.5 64 Gb Wi-Fi Space Grey (MQDT2RU/	Apple	iPad Pro 10.5 64 Gb Wi-Fi серый космос (
4226285	Унитаз Teymi подвесной безободковый с инсталляцией и клавише	Teymi	T70011/T70103BM/T40110
4226268	Унитаз Teymi подвесной безободковый с инсталляцией и клавише	Teymi	T70011/T70019WM/T40106

sku_id	title	vendor	model
4226260	Унитаз Teymi подвесной безободковый с инсталляцией и клавише	Teymi	T70011/T70203BM/T40106

4. Анализ текстовых карточек

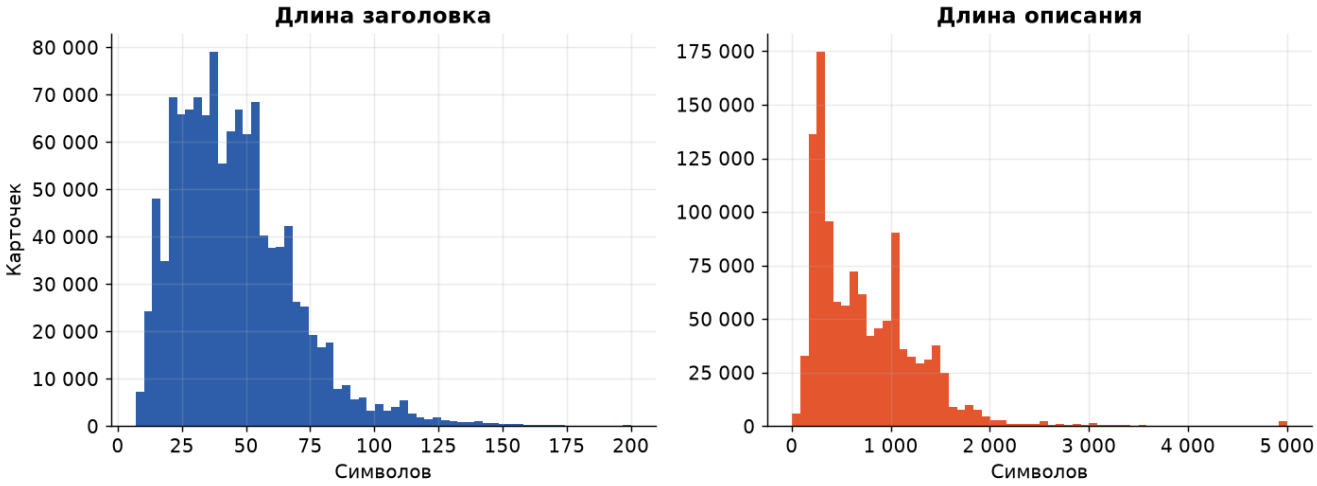


Рис. 3. Распределение длин заголовков и описаний.

Метрика	Заголовок	Описание
Средняя длина	45,9	752,6
Медиана	43	630
95-й перцентиль	88	1 634
99-й перцентиль	124	2 737
Максимум	288	27525
Содержит цифры	65,1%	82,4%
Содержит HTML-теги	0,0%	49,3%
Содержит переносы строк	0,0%	33,1%

Заголовки короткие и плотные (медиана 43 символа), почти всегда содержат цифры и латиницу — это основная зона для извлечения бренда, модели и ключевых параметров. Описания длинные и почти в половине случаев содержат HTML-разметку, которую нужно чистить перед извлечением.

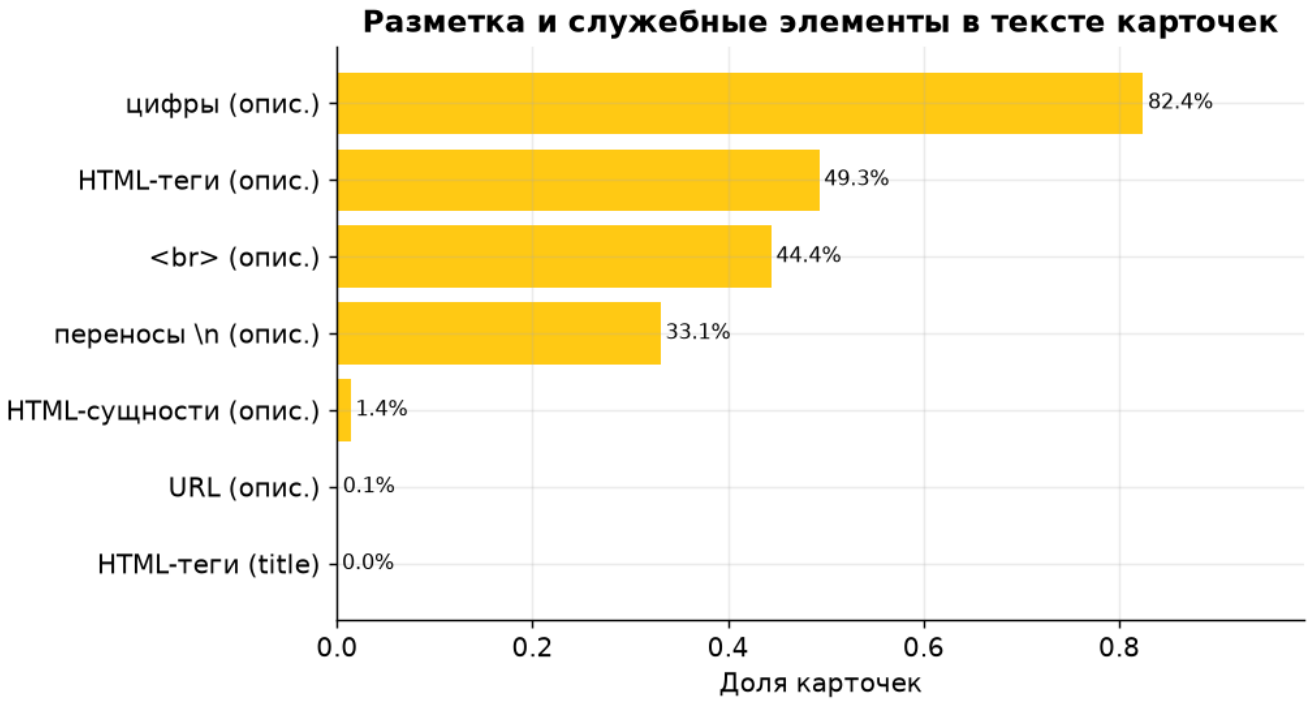


Рис. 4. Разметка и служебные элементы в тексте.



Рис. 5. Языковой состав заголовков.

Язык: **96,0%** заголовков смешанные (кириллица + латиница: бренд/модель латиницей, тип товара — по-русски), 4,0% — только кириллица. Это подтверждает, что нормализация должна уметь сопоставлять латинские бренды и русские термины.

4.1. Качество текста и аномалии



Рис. 6. Дубликаты и повторяющиеся шаблоны.

Признак	Доля / значение
Дубликаты заголовков	484 361 (41,1%)
Дубликаты описаний	260 320 (22,1%)
Маркер «Лучшие товары из Китая»	179 968
Маркер «Характеристики:»	337 099
Маркер «Комплектация:»	71 554
URL в описании	0,1%
Мойибейк / битая кодировка	0,0%

Почти **41,1%** заголовков повторяются — например, «Косметичка UNIMALL -» встречается сотни раз. Это типичные «пустые» карточки без конкретики: их нельзя использовать как самостоятельные примеры, атрибуты придётся брать из описания. Большая доля описаний содержит рекламные «шаблоны» продавцов — их следует вырезать как шум.

5. Каталог: категории и параметры

Каталог содержит **546 069** офферов в **3 599** категориях. Среднее число параметров на оффер — **38,4** (медиана 27, максимум 301).

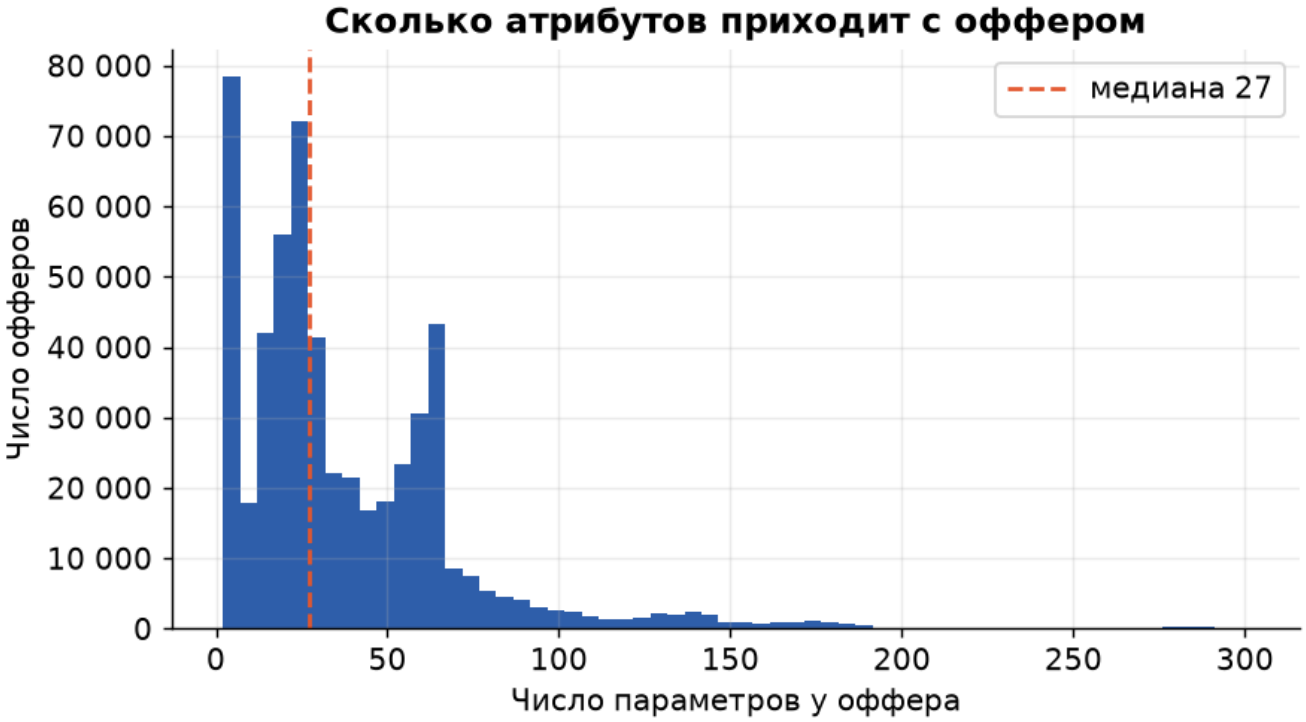


Рис. 7. Распределение числа атрибутов на оффер.

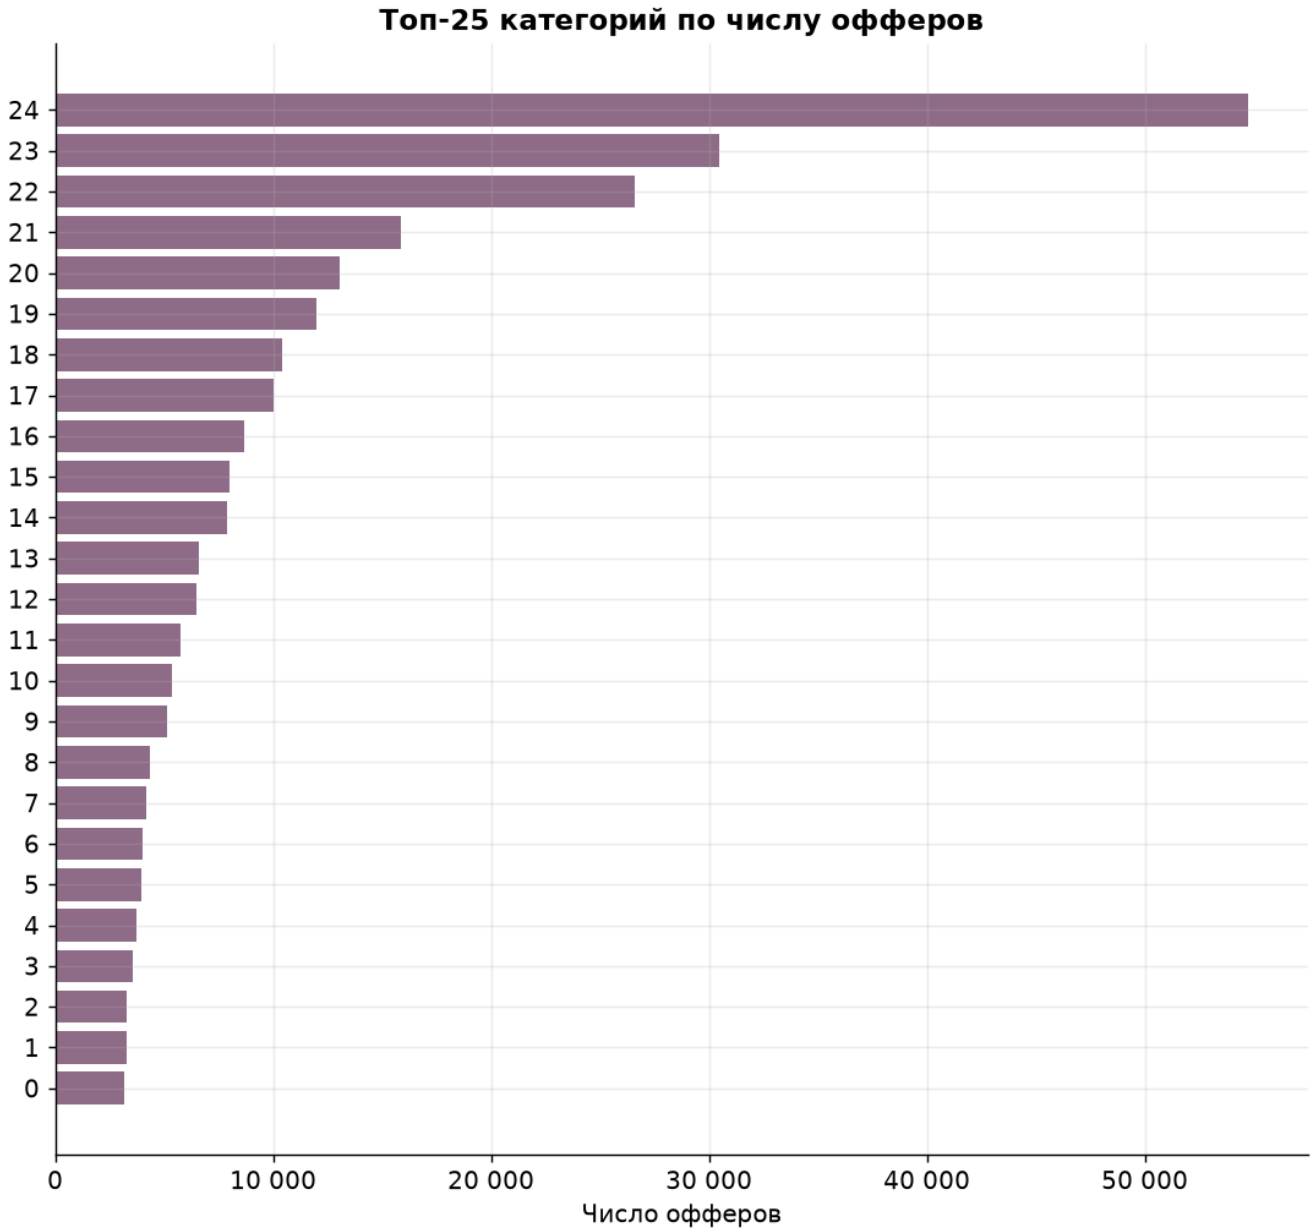


Рис. 8. Крупнейшие категории каталога.

5.1. Словарь атрибутов и длинный хвост

После слияния дублей с суффиксом `_search` остаётся **10 708** уникальных имён атрибутов (сырых — **12 999**, из них 69,4% с суффиксом `_search`). Распределение крайне неравномерное: **284** имён встречаются более 10 000 раз, а **5 486** — реже 100 раз, **1 517** — реже 5 раз.

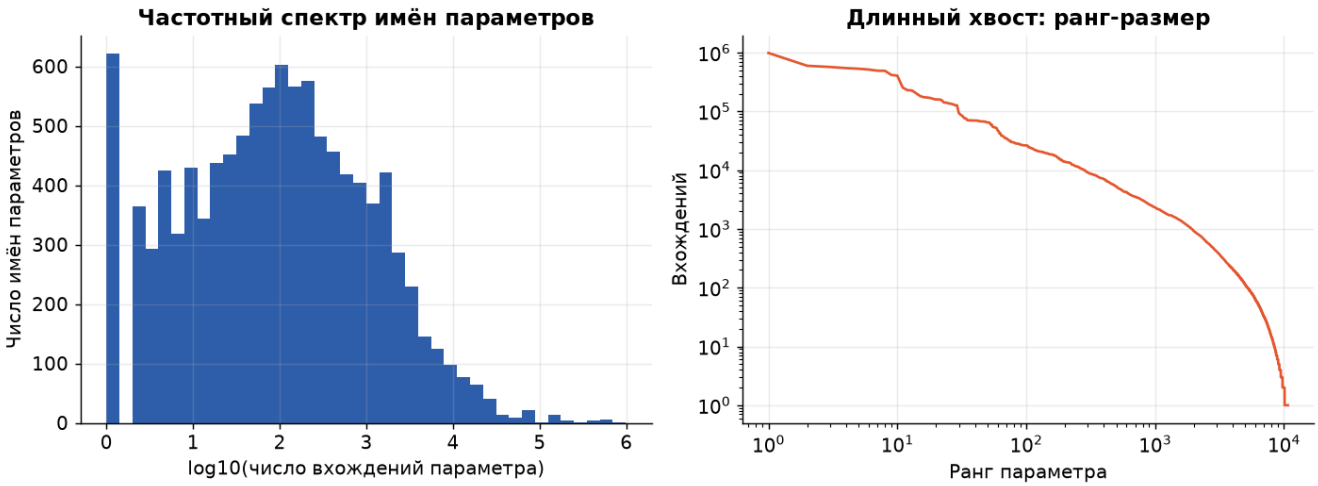


Рис. 9. Частотный спектр и длинный хвост имён атрибутов.

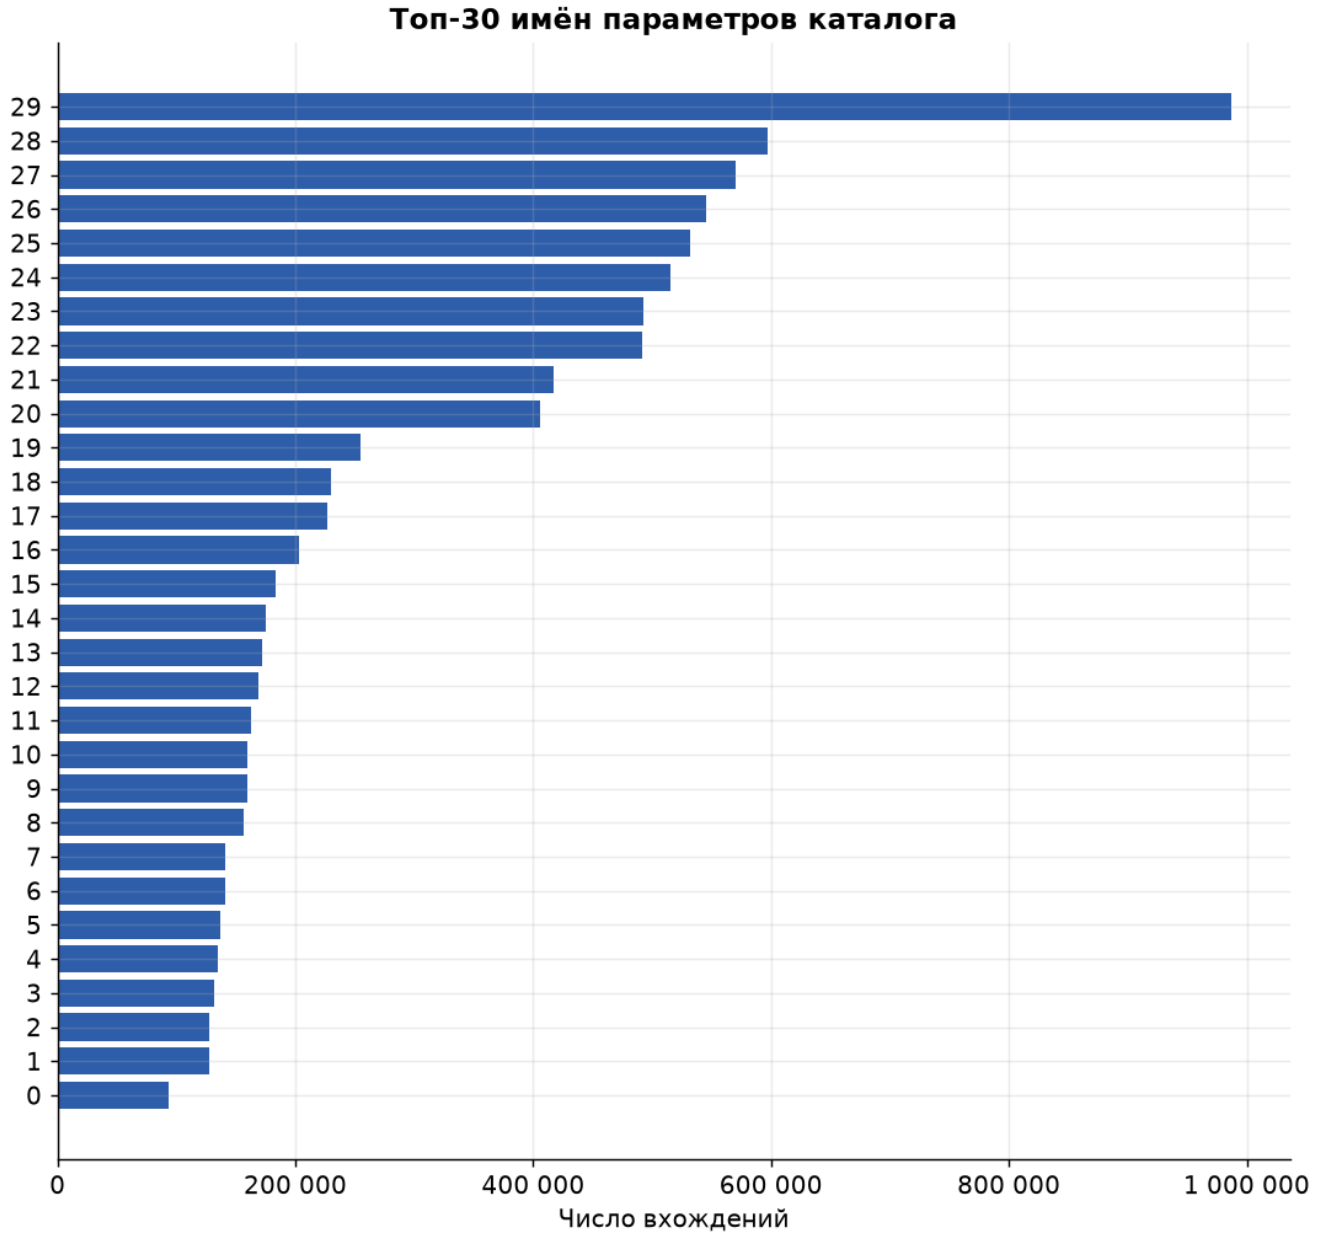


Рис. 10. Топ-30 имён параметров.

Обратите внимание: верхние строки рейтинга — не товарные характеристики, а служебные и маркетинговые поля: **Подборки**, **Продавец**, **Потратить бонусы**, **Гарантия**,

Гарантия предоставляется, **Страна**. Их обязательно нужно исключать из целевой схемы извлечения.

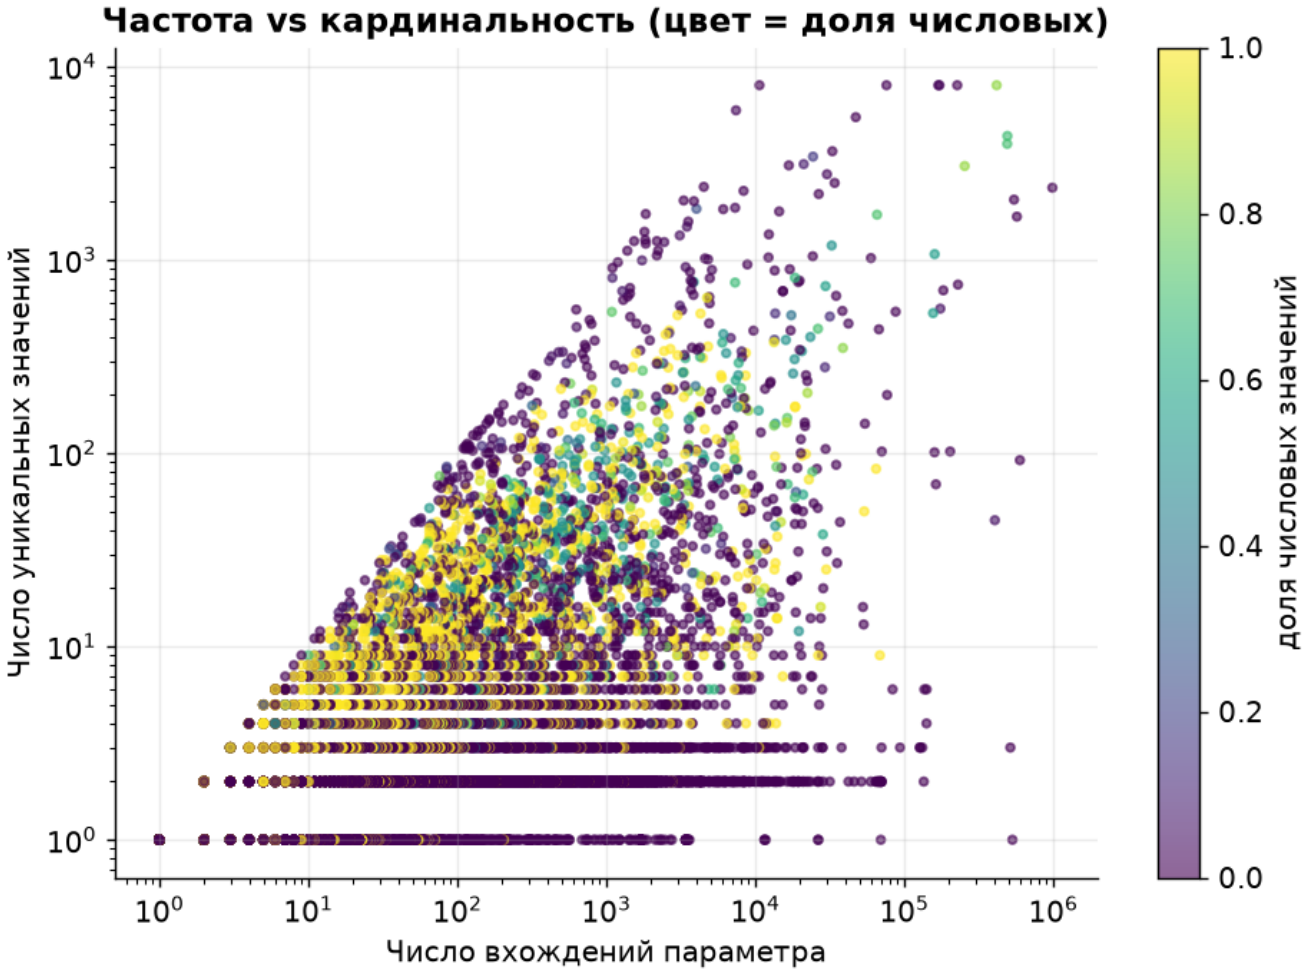


Рис. 11. Частота vs кардинальность (цвет — доля числовых значений).

Диаграмма разделяет атрибуты на два класса: числовые с низкой кардинальностью (размеры, вес, мощность) и категориальные/текстовые с высокой кардинальностью (модели, серии, артикулы). Первый класс хорошо закрывается правилами и единицами измерения; второй — длинный хвост, требующий ML/LLM и словарей.

6. Целевые категории и атрибуты

Ниже — заполненность ключевых атрибутов по 12 важнейшим категориям электроники кейса. Значения — доля офферов, у которых атрибут заполнен и попадает в фильтры поиска. Коды атрибутов соответствуют доменной модели (`openspec/specs/domain-model.md`): `brand`, `model`, `color`, `storage`, `drive`, `ram`, `diagonal`, `battery_capacity`, `processor`.

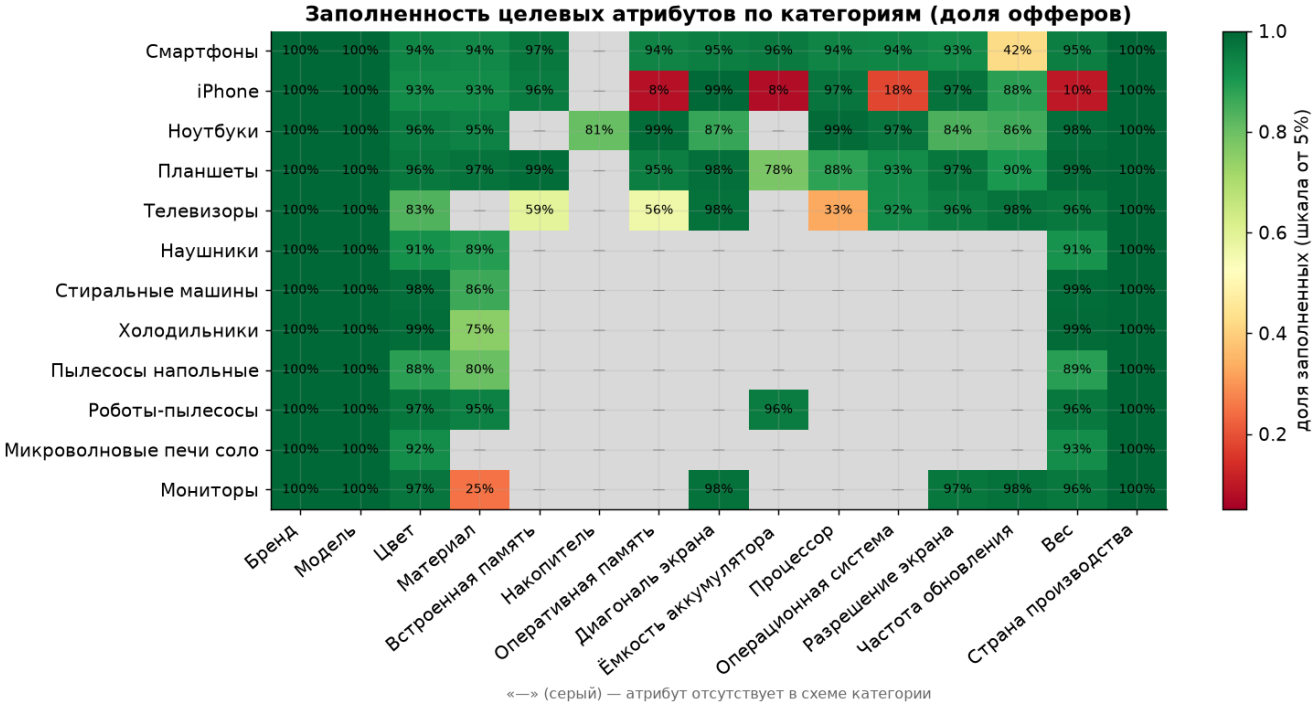


Рис. 12. Заполненность целевых атрибутов по категориям. Серые ячейки («—») — атрибут отсутствует в схеме категории; цветовая шкала нормирована на фактический диапазон данных, чтобы была видна разница между высокими значениями.

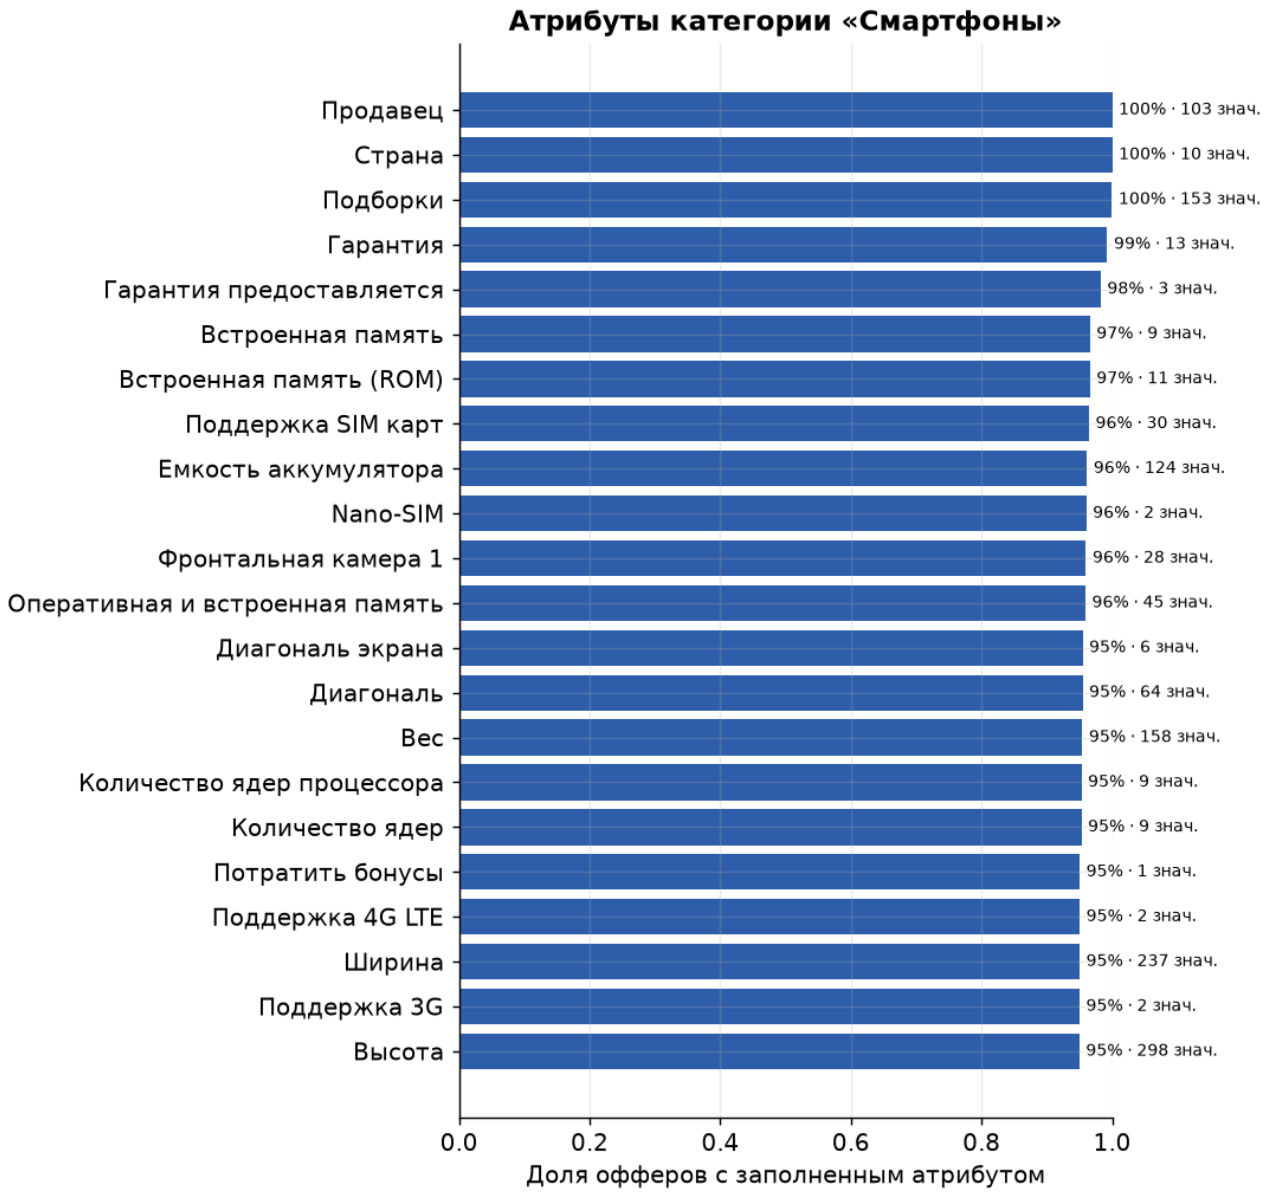


Рис. 13. Атрибуты смартфонов: заполненность и число уникальных значений.

6.1. Пример схемы атрибутов смартфона

Атрибут	Офферов	Заполнено	Уник. знач.	Топ-значения
brand (vendor)	7 988	100,0%	45	
model	7 988	100,0%	5 188	
Продавец	7 988	100,0%	103	М.Видео (2532) | ООО "Холодильник.Ру" (534) | НО
Страна	7 988	100,0%	10	Китай (5116) | Вьетнам (2713) | Индия (62)
Подборки	7 986	100,0%	153	с мощным аккумулятором (7663) | игровые (7550) |

Атрибут	Офферов	Заполнено	Уник. знач.	Топ-значения
Гарантия	7 929	99,3%	13	1 год (5590) | 3 месяца (979) | 1 месяц (899)
Гарантия предоставляется	7 848	98,2%	3	производителем (6710) | продавцом (1137) | поста
Встроенная память	7 716	96,6%	9	256 ГБ (3776) | 512 ГБ (1989) | 128 ГБ (1503)
Встроенная память (ROM)	7 716	96,6%	11	256 ГБ (3776) | 512 ГБ (1989) | 128 ГБ (1503)
Поддержка SIM карт	7 705	96,5%	30	2 nano-SIM (2735) | 2 nano-SIM/1 eSim (1588) | 2
Емкость аккумулятора	7 681	96,2%	124	3000-5000 мАч (4476) | 5001-7000 мАч (2950) | 50
Nano-SIM	7 671	96,0%	2	Да (7628) | Нет (43)
Фронтальная камера 1	7 668	96,0%	28	12 (2475) | 32 (1263) | 13 (783)
Оперативная и встроенная память	7 661	95,9%	45	8 ГБ/256 ГБ (2019) | 12 ГБ/256 ГБ (1547) | 12 ГБ

6.2. Пример схемы атрибутов ноутбука

Атрибут	Офферов	Заполнено	Уник. знач.	Топ-значения
brand (vendor)	3 580	100,0%	64	
model	3 580	100,0%	2 846	
Продавец	3 580	100,0%	79	М.Видео (960) | ИП Хохлов Петр Петрович (640) |
Подборки	3 580	100,0%	64	для учёбы (3580) | для дома (3580) | беспроводны
Страна	3 580	100,0%	9	Китай (3354) | Россия (76) | Тайвань (76)
3Д для отчета BI/BO	3 553	99,2%	1 577	Liquid Retina XDR/Apple/M4/10 ГБ/macOS (55) | 13
Процессор	3 541	98,9%	748	Apple M4 4.41 ГГц (132) | Apple M4 (115) | Apple
Оперативная память	3 535	98,7%	15	16 ГБ (2198) | 8 ГБ (555) | 32 ГБ (366)
Оперативная память (RAM)	3 535	98,7%	15	16 (2198) | 8 (555) | 32 (366)

Атрибут	Офферов	Заполнено	Уник. знач.	Топ-значения
Потратить бонусы	3 524	98,4%	1	Да (3524)
Модель процессора	3 520	98,3%	151	Core i5 (527) | M4 (359) | M5 (320)
Вес	3 516	98,2%	135	от 1.5 до 2 кг (1602) | от 1 до 1.5 кг (1024) |

Наблюдения по схемам:

- Ядро схемы повторяется: бренд, модель, цвет, материалы, габариты/вес, страна. Дальше — категорийные атрибуты (память, экран, процессор для смартфонов; ОС, клавиатура для ноутбуков).
- Атрибуты-«двойники» хранятся в каталоге отдельными параметрами («Встроенная память» и «Встроенная память (ROM)», «Оперативная память» и «Оперативная память (RAM)») — при анализе они сведены к единым кодам `storage` и `ram`.
- Встроенная память (`storage`) и накопитель (`drive`) — разные атрибуты: у смартфонов заполнена встроенная память, у ноутбуков — накопитель (SSD/HDD).
- Часть полей — ведра/диапазоны для фильтров: «Диагональ экрана» = «6.6" и более», «Емкость аккумулятора» = «3000-5000 мАч». Рядом живёт точное значение («Диагональ» = 6.7). Это два разных представления одного атрибута.
- Есть полностью служебные поля, которые не являются товарными характеристиками («ЗД для отчета BI/BO», «Продавец», «Подборки», «Гарантия предоставляется», «Потратить бонусы»).
- Бренд и модель заполнены в 100% офферов — это самые надёжные атрибуты и хорошие первичные ключи для сопоставления товаров.

6.3. Коды доменной модели для приёмочных категорий

Соответствие кодов атрибутов доменной модели для категорий из приёмочных тест-кейсов (`openspec/specs/attribute_extractor.md`, §7.4). Заполнено — доля офферов с атрибутом в каталоге.

Смартфоны

Код	Атрибут	Заполнено
brand	Бренд	100,0%
model	Модель	100,0%
color	Цвет	93,7%
material	Материал	93,7%
storage	Встроенная память	96,6%
ram	Оперативная память	94,4%
diagonal	Диагональ экрана	95,5%
battery_capacity	Ёмкость аккумулятора	96,2%

Код	Атрибут	Заполнено
processor	Процессор	94,3%
os	Операционная система	93,9%
resolution	Разрешение экрана	92,7%
refresh_rate	Частота обновления	42,1%
weight	Вес	95,4%
country	Страна производства	100,0%

Ноутбуки

Код	Атрибут	Заполнено
brand	Бренд	100,0%
model	Модель	100,0%
color	Цвет	95,8%
material	Материал	94,8%
drive	Накопитель	80,5%
ram	Оперативная память	98,7%
diagonal	Диагональ экрана	86,9%
processor	Процессор	98,9%
os	Операционная система	97,4%
resolution	Разрешение экрана	84,1%
refresh_rate	Частота обновления	85,8%
weight	Вес	98,2%
country	Страна производства	100,0%

7. Нормализация значений и единиц

Отдельный слой анализа — насколько «грязны» значения. Ключевое наблюдение: в структурированном каталоге значения в основном уже приведены к словарю и единицам, но форматы всё ещё расходятся, а входной текст карточек не нормализован вовсе.

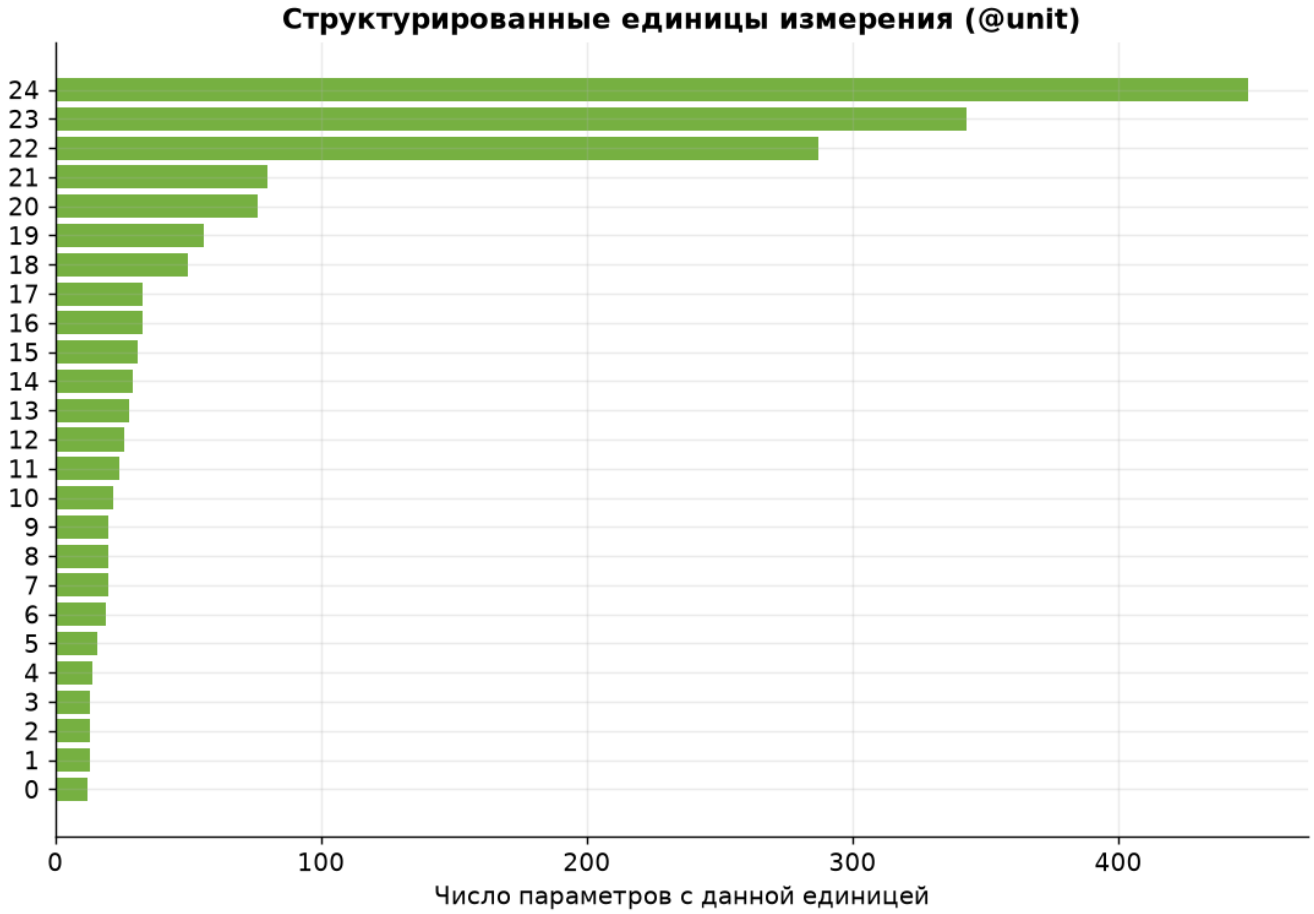


Рис. 14. Структурированные единицы измерения (@unit).

Единицы в поле `@unit` каталога стандартизованы (см, кг, шт, мм, Вт, ГБ...), но многие числовые атрибуты хранят единицу прямо в значении без `@unit` («Высота» = «30 см»). То есть пайплайн должен уметь разбирать число и единицу и из значения, и из отдельного поля.

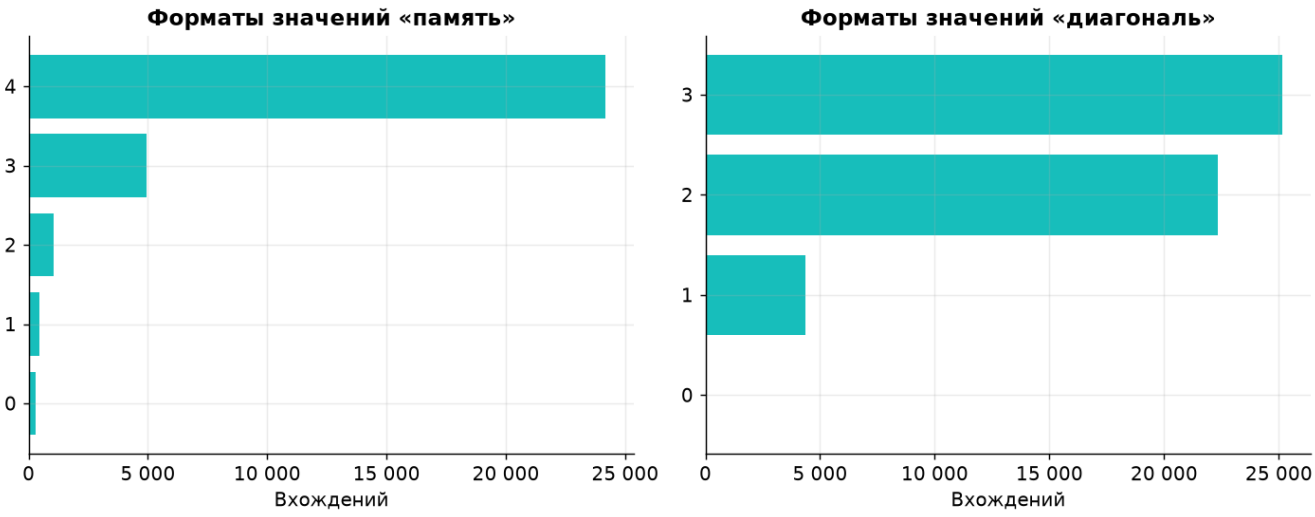


Рис. 15. Форматы значений для памяти и диагонали экрана.

Атрибут	Всего значений	Уникальных	Основные форматы
Встроенная память	30 920	66	число без единицы: 4 934, число+ГБ(кир): 24 169, текст/диапазон: 471, число+МБ: 311, число+ТБ: 1 035
Диагональ экрана	51 822	455	дюймы: 25 141, число без единицы: 22 317, текст/диапазон: 4 360, сантиметры: 4
Цвет	585 294	1 675	после lower/ё: 1 592, коллизий: 75

Память: всего 66 уникальных значений — словарь уже узкий, но диагональ хранится и в дюймах, и просто числом, и в виде диапазонов («от 15 до 16.9»). Цвет: 1 675 уникальных значений, из которых 83 — дубликаты по регистру и букве «ё» («черный»/«чёрный»/«Черный»), плюс составные цвета через слэш.

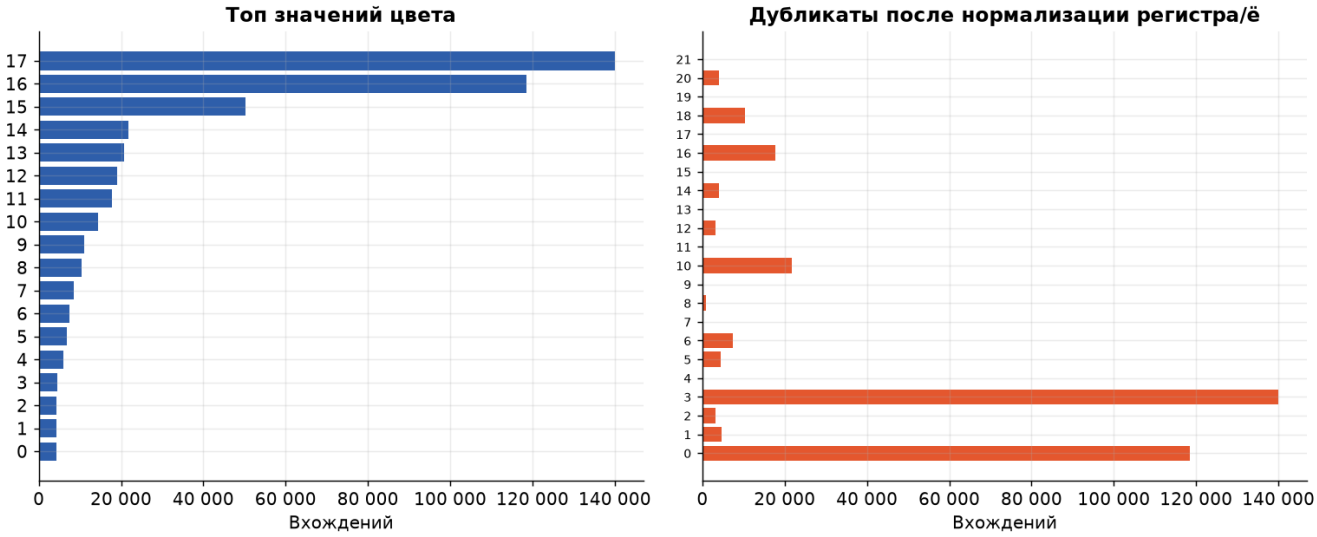


Рис. 16. Топ значений цвета и дубликаты после нормализации.

Примеры коллизий цвета (разные написания одного значения):

Каноническое (после lower/ё)	Варианты написания
черный	черный (118497), чёрный (4601), Черный (3168)
белый	белый (139945), БЕЛЫЙ (3), Белый (4377)
коричневый	коричневый (7350), Коричневый (1)
белый/бежевый	белый/бежевый (849), Белый/Бежевый (316)
серый	серый (21794), Серый (103)
черный матовый	черный матовый (3177), Черный матовый (20)
нержавеющая сталь	нержавеющая сталь (4031), Нержавеющая сталь (70)
серебристый	серебристый (17733), Серебристый (18)
синий	синий (10349), Синий (55)

Каноническое (после lower/ё)	Варианты написания
розовый	розовый (4072), Розовый (8)
другие	другие (1932), Другие (317)
красный	красный (5958), Красный (2)

8. Кликовый трафик

Трафик — источник весов важности атрибутов: **30 991 350** показов/кликов, **332 753** SKU, **4 103** тематик. Атрибуты, по которым чаще фильтруют и которые чаще встречаются в популярных категориях, приносят больше пользы и должны весить больше в метрике.

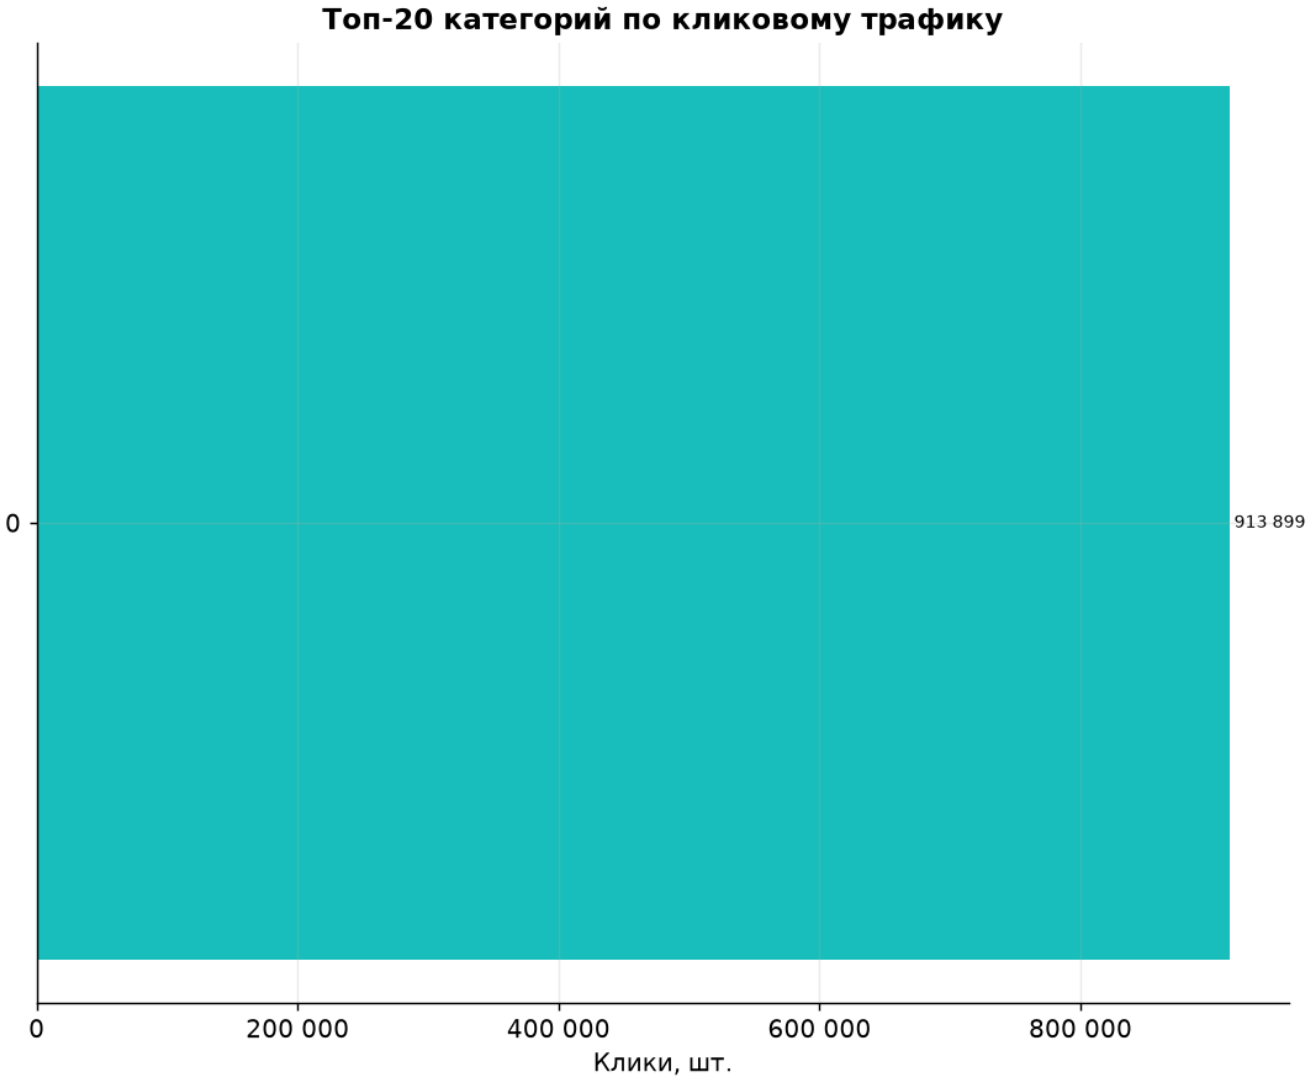


Рис. 17. Топ-20 категорий по кликовому трафику.

Самые «трафиковые» категории — бытовая техника и электроника: стиральные машины, холодильники, телевизоры, ноутбуки, смартфоны, наушники. Именно здесь заполненность атрибутов напрямую влияет на CTR и конверсию.

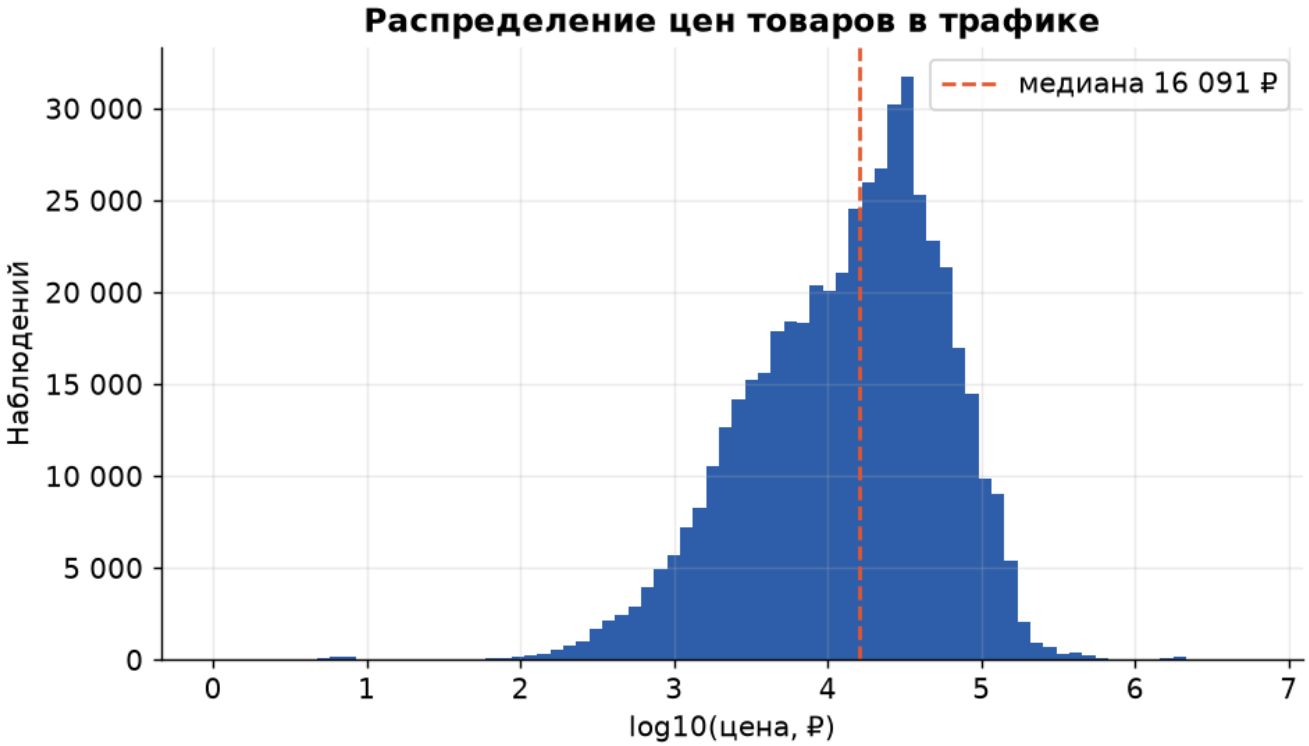


Рис. 18. Распределение цен в трафике.

Метрика цены	Значение, ₽
Средняя	31 084
Медиана	16 091
1-й перцентиль	231
99-й перцентиль	176 705
Максимум	11 900 000
Доля нулевых цен	0,4%

Аномалия: **116 391** строк с нулевой ценой (0,4%) — товары без цены, их нужно исключать из ценовых признаков. Отрицательных цен нет. Распределение цен логнормальное с длинным правым хвостом (максимум 11 900 000 ₽).



Рис. 19. Распределение кликов по позициям в выдаче.

Кликовый трафик сконцентрирован в начале выдачи: позиция 0 даёт **23,8%** кликов. Максимальная позиция — 5 893. Это подтверждает ценность корректных атрибутов: они поднимают товар в фильтрах и в самых горячих позициях.

9. Сводка аномалий и проблем данных

#	Проблема	Масштаб	Как учитывать
1	Низкое пересечение источников	241 355 SKU (текст+эталон)	обучаться/валидироваться только на пересечении
2	Дубликаты заголовков карточек	41,1%	дедуплицировать, брать атрибуты из описания
3	HTML-разметка в описаниях	49,3%	очистка тегов перед извлечением
4	Маркетинговые «шаблоны» продавцов	179 968 вхождений фразы	вырезать как шум
5	Служебные «атрибуты» в каталоге	Подборки, Продавец, Гарантия, BI-поля	исключить из целевой схемы
6	Атрибуты-двойники	«Встроенная память» / «(ROM)»	канонизировать в один код
7	Ведра/диапазоны вместо значений	«6.6" и более», «3000-5000 мАч»	различать точное значение и фильтр-фасет
8	Длинный хвост атрибутов	5 486 имён < 100 вхождений	правила + ML/LLM, не только словарь
9	Грязь цвета (регистр, ё, составные)	75 групп коллизий	lowercase + ё→е + словарь цветов
10	Нулевые цены в трафике	0,4%	исключать из ценовых признаков
11	Цвет почти не заземляется в тексте	16,8%	извлекать из структуры/словаря, не из текста
12	Смешение языков и транслитерация	96,0% заголовков RU+EN	нормализация латиница↔кириллица

10. Выводы и рекомендации

10.1. Что показал EDA

- Данные полуструктурированы: **эталон атрибутов лежит в структурированных параметрах каталога**, а неструктурированный вход — это текст карточек. Пайплайн должен соединять оба мира.
- Ядро атрибутов (бренд, модель, цвет, материалы, габариты) повторяется почти во всех категориях — его можно закрыть правилами и словарями. Категорийный хвост и редкие значения — зона ML/LLM.
- Бренд и модель хорошо извлекаются из заголовка (98% и 96%). Цвет — нет (17%): нужен словарь и структурный источник.
- Таксономия огромна (10,7к имён атрибутов), с сильным длинным хвостом — единая ручная разметка невозможна, нужна автоматическая канонизация на базе словарей каталога.

10.2. Рекомендации по пайплайну

- **Источник схемы атрибутов**: строить канонический реестр атрибутов из параметров каталога по категории, отфильтровав служебные поля (Подборки, Продавец, Гарантия, BI-поля).
- **Словарь значений**: взять допустимые значения атрибутов прямо из каталога (память, цвет, диагональ уже почти нормализованы) — это даёт бесплатный grounding и валидацию.
- **Препроцессинг текста**: снятие HTML, удаление рекламных «шаблонов», нормализация пробелов, регистра и ё→е, транслитерация брендов.
- **Каскад cheap-first**: правила/словари для ядра и числовых полей → NER/классификатор для хвоста → LLM только на нетиповых карточках с ограничением схемой вывода.
- **Категория**: карточки sku_desc не содержат категорию — определять её классификатором по тексту или подтягивать из каталога по SKU на этапе валидации.
- **Метрика**: считать precision/recall/F1 по каждому атрибуту и взвешивать по трафику (query_clicks) — приоритет отдавать атрибутам горячих категорий.
- **Валидация**: hold-out на подмножестве SKU с текстом и трафиком; отдельно контролировать редкие категории и редкие значения.

10.3. Риски

- Галлюцинации LLM — ограничить схемой и проверкой заземления значения в тексте.
- Дисбаланс по категориям — контролировать метрику на редких категориях отдельно.
- Низкое пересечение источников ограничивает объём размеченных пар «текст → атрибуты».
- Дрейф каталога (новые товары/категории) — правила и словари нужно регулярно обновлять.

Артефакты EDA: `EDA/figures/` (21 график), `EDA/results/` (таблицы CSV), `EDA/cache/` (агрегаты), `EDA/src/` (воспроизводимый код).